

Report

1. Synergies

DeepXplore는 임의의 테스트 이미지를 시드로 삼아 gradient ascent를 진행하는데, 출발점이 모델의 decision boundary와 얼마나 가깝느냐에 따라 수렴 속도가 크게 달라진다. 두 모델 모두 쉬운 이미지를 시드로 쓸 경우 불일치 유발까지 수십 번의 iteration이 소요되었다. 반면, PGD로 사전 처리된 이미지처럼 이미 결정 경계 근방에 놓인 입력은 소수의 iteration만으로 불일치를 유발할 가능성이 있다.

적대적 예제는 모델이 아슬아슬하게 정답을 내뱉는 입력이며, 두 모델이 서로 미세하게 다른 비선형 경계를 학습했다는 사실을 감안하면, 경계 근방 입력이 두 모델이 갈라지기 가장 쉬운 위치다. 따라서 적대적 예제는 차이점 테스트의 탐색 효율을 높이는 동시에, 더 의미 있는 불일치 (노이즈가 아닌 모델의 구조적 의사결정 차이에서 비롯된 불일치)를 찾아낼 가능성을 높인다.

반대 방향의 시너지도 성립한다. 뉴런 커버리지 지표를 공격의 탐색 가이드로 활용하면, 아직 활성화되지 않은 경로를 선택적으로 노출시키는 방향으로 perturbation의 타격을 결정할 수 있다. 모델 내부에서 평소에는 쓰이지 않는 뉴런 경로를 의도적으로 자극하는 공격이 가능해짐을 의미한다.

2. Coverage-guided Attacks

Coverage 기반 공격은 딜레마가 존재한다. FGSM/PGD에서 목적함수는 단일 방향(오분류 유도)으로 설계되어 발산이 잘 생기지 않는다. 그런데 여기에 "미활성 뉴런 활성화"라는 항목을 추가하는 순간, 두 목표는 반드시 같은 방향을 가리키지 않는다. 어떤 미활성 뉴런을 살리는 방향의 perturbation이 오히려 분류 확률분포를 안정시키는 방향으로 작용할 수도 있기 때문이다. 즉, 두 항목 간의 가중치(weight_diff, weight_nc)를 어떻게 설정하느냐에 따라 공격의 성격이 달라진다.

코드를 돌려보며 커버리지는 "불일치를 더 빠르게 찾게 해주는 정규화 항"에 가깝게 작동했다. 단독으로 강하게 적용하면 오히려 불일치 유발 실패율이 높아졌다. 이는 coverage-guided attack이 유효하게 동작하려면 두 목표가 충돌하지 않는 탐색 공간의 부분집합을 찾아야 한다.

3. Efficiency

두 기법의 결합이 버그 탐색 속도를 실질적으로 높이는지 판단하려면, 어떤 조건 하에서 효율 개선이 발생하는지를 명확히 해야한다. 동일한 ResNet50 아키텍처를 공유하는 두 모델이 초기 시드(seed 10 vs 20)만 다르게 설정했을 뿐인데, 실제 불일치 결과를 보면 "M1은 bird로, M2는 plane으로" 분류하는 식의 큰 예측 격차가 발생했다. 두 모델이 같은 데이터, 같은 구조, 같은 학습 방식으로 훈련되었음에도 결정 경계의 형태가 달라진 것은, 신경망이 학습 중 어떤 feature를 우선적으로 잡아내느냐가 초기 gradient 흐름에 크게 의존한다는 점을 보여준다.

이 격차가 클수록 FGSM/PGD로 생성된 perturbation이 차이점 테스트에서 더 빠르게 분기를 유발하는 시드로 기능할 가능성이 높다. 즉, 두 모델 간의 feature diversity가 클수록 공격과 테스트의 결합 효율도 높아지는 비례 관계가 성립한다. 역으로 말하면, 두 모델이 거의 동일한 feature에 의존할수록 적대적 예제를 시드로 쓰는 효과가 사라지며, 결합의 이득이 줄어든다.

4. Limitations

첫번째 한계는 의미 있는 입력의 범위 문제다. PGD 공격은 L_{∞} norm 에서 진행되어 perturbation의 크기가 제한되고, 생성된 이미지는 원본과 시각적 구별이 어렵다. 그러나 DeepXplore는 iteration이 쌓이면서 점점 원본 이미지와 동떨어진 방향으로 이미지를 변형시킬 수 있으며, step이 누적되면 현실적 입력과 연결되지 않는 추상적 픽셀 패턴이 만들어진다.

두 기법을 결합할 때 L_p norm이나 입력 분포에 대한 정규화를 병행하지 않으면, 결합의 산출물은 오히려 실제적 가치가 희박한 이론적 결합 사례만 양산할 위험이 있다. 결합의 효용은 탐색 공간에 현실적 제약을 잘 부과하는 것에 달려있다.

커버리지 지표의 신뢰성 문제도 존재한다. threshold를 0.0에서 0.1로 올렸을 때 커버리지 수치가 낮아지는 현상은, DeepXplore가 달성하는 "높은 커버리지"의 상당 부분이 뉴런이 0에 가까운 값으로만 미세하게 반응했을 때도 "커버됨"으로 처리되는 측정 아티팩트에 기인함을 시사한다. "neuron coverage is too easy to saturate"라는 비판이 확인된 셈이다. 이는 coverage-guided attack 연구에서 비교 실험 설계 시 threshold를 반드시 명시해야 할 핵심 변수로 다루어야 함을 의미한다.